

Proyecto Final - Precios de SUVs

Eliana Ostrovsky
Departamento de Ingenieria
Universidad de San Andres
eostrovsky@udesa.edu.ar

Valentino Arbelaiz Alberti
Departamento de Ingenieria
Universidad de San Andres
varbelaizalberti@udesa.edu.ar

Abstract—En este trabajo desarrollamos un modelo predictivo para estimar el precio en dólares de vehículos tipo SUV publicados en MercadoLibre Argentina durante mayo de 2025. A partir de un conjunto de aproximadamente 18.000 registros, se realizó un análisis exploratorio y una exhaustiva limpieza de datos, incluyendo la normalización de textos, reducción de cardinalidad en versiones mediante clustering (DBSCAN), extracción de información técnica y codificación de variables categóricas. También se aplicaron técnicas de reducción de dimensionalidad y eliminación de outliers.

Para la predicción se probaron distintos modelos de regresión, incluyendo regresión lineal, Random Forest, XGBoost y un perceptrón multicapa. Tras una etapa de ajuste de hiperparámetros utilizando búsquedas aleatorias, bayesianas y Optuna, el modelo que mostró mejor rendimiento fue XGBoost, logrando el menor error cuadrático medio (RMSE) y el mayor coeficiente de determinación (R^2) en el conjunto de validación. El modelo final fue evaluado utilizando RMSE sobre el conjunto de test, obteniendo un valor aproximado de 6.000 dólares y un R^2 de 0.944.

Index Terms—component, formatting, style, styling, insert.

I. INTRODUCCIÓN

El mercado de autos usados presenta una alta variabilidad de precios, influenciada por múltiples factores como el estado del vehículo, la marca, el kilometraje, el año de fabricación y la oferta disponible. En este contexto, contar con un modelo automatizado que permita predecir el valor de un vehículo en función de sus características representa una herramienta valiosa tanto para compradores como para vendedores.

Este trabajo se enfoca en el desarrollo de un modelo predictivo capaz de estimar el precio de SUVs publicados en la plataforma MercadoLibre Argentina durante el mes de mayo de 2025. A partir de un conjunto de datos reales, se busca construir un pipeline robusto de procesamiento, selección de características y modelado, capaz de generalizar a nuevas observaciones.

El problema se plantea como una tarea de regresión supervisada: el modelo recibe como entrada diversas variables descriptivas del vehículo (como marca, modelo, versión, color, kilometraje, entre otras) y devuelve como salida una predicción del precio en dólares. Para evaluar la calidad del modelo, se utiliza como métrica principal el *Root Mean Squared Error* (RMSE), que permite cuantificar la diferencia promedio entre los valores reales y los estimados. Además, se compara el desempeño entre distintos algoritmos utilizando el coeficiente de determinación R^2 .

El objetivo final es obtener un modelo preciso, interpretable y generalizable, que pueda servir como base para aplicaciones prácticas como la detección de oportunidades de compra o el análisis del mercado automotor.

II. CONJUNTO DE DATOS Y CARACTERÍSTICAS

El dataset utilizado contiene aproximadamente 18.000 registros de vehículos tipo SUV publicados en la plataforma MercadoLibre Argentina entre el 13 y el 30 de mayo de 2025. Cada registro representa una publicación con múltiples atributos descriptivos. Las columnas originales incluyen información técnica y comercial como: marca, modelo, año, versión, color, tipo de combustible, número de puertas, tipo de transmisión, motorización, tipo de carrocería, presencia de cámara de retroceso, kilometraje, título, precio, moneda y descripción del vehículo.

A. División de datos

Los datos fueron divididos en un 80% para entrenamiento y validación, y un 20% para testeo final. A su vez, dentro del conjunto de entrenamiento se separó el 20% para validación, resultando en una proporción aproximada de 64% entrenamiento, 16% validación y 20% test.

B. Análisis exploratorio y visualizaciones

Se realizó un análisis exploratorio inicial para comprender la distribución de las variables más relevantes. Entre los gráficos construidos se destacan:

- Distribución del precio, separando entre autos nuevos y usados. Ambas distribuciones mostraron una forma similar a una distribución de Poisson, aunque con diferentes parámetros. Como era de esperar la media de los autos nuevos era mucho mas alta.
- Frecuencia de publicaciones por marca, donde se observó una fuerte desproporcionalidad: algunas marcas contaban con cientos de registros, mientras que otras tenían apenas una decena.
- Relación entre kilómetros recorridos y precio. Como muestra la Figura 1 podemos ver que estan inversamente relacionados. Para hacer la figura elegimos mostrar un solo modelo de auto para mejorar la visibilidad, pero todo el dataset sigue esta distribución.

A continuación, se muestra un ejemplo de registro tal como aparece en el dataset original antes del preprocesamiento:




Fig. 1. Relación entre kilómetros recorridos y precio de los autos. Filtrado mostrando solamente los auto Eco-sport.

TABLE I
EJEMPLO DE REGISTRO CRUDO DEL DATASET ORIGINAL

Columna	Valor
Marca	Ford
Modelo	Ecosport
Año	2020
Versión	1.5 Freestyle 123cv 4x2
Color	Blanco
Combustible	Nafta
Puertas	5.0
Transmisión	Manual
Motor	1.5
Carrocería	SUV
Cámara de retroceso	No
Kilómetros	64000
Título	Ford Ecosport 1.5 Freestyle 123cv 4x2
Precio	20500000
Moneda	\$
Descripción	Descubre nuestro impresionante Ford..

La descripción fue truncada por brevedad.

C. Preprocesamiento y construcción de features

Se llevó a cabo un proceso de limpieza exhaustivo para corregir inconsistencias en los datos textuales. En particular, la columna *Versión* presentaba una altísima variabilidad debido a su naturaleza de texto libre, con más de 1.100 valores únicos cargados de forma inconsistente por los usuarios. Para reducir su cardinalidad, se construyeron representaciones vectoriales utilizando *CountVectorizer*, sobre las cuales se aplicó una estrategia combinada de *matching* por similitud y agrupamiento.

Primero, se compararon todas las versiones contra un catálogo externo de versiones oficiales¹, calculando la similitud de coseno entre los vectores. Si la mayor similitud superaba un umbral de 0,3, se asignaba la versión oficial correspondiente. En caso contrario, se aplicó el algoritmo de clustering DBSCAN sobre los embeddings para agrupar automáticamente las versiones que no coincidían con el catálogo, identificando agrupamientos densos de nombres similares sin

¹La lista de versiones oficiales fue obtenida mediante *scraping* de publicaciones de Mercado Libre Argentina, mayo 2025.

requerir definir un número de clústeres preestablecido. Cada grupo resultante fue rotulado con la variante más frecuente dentro del mismo. Este proceso permitió reducir la cardinalidad de *Versión* a aproximadamente 200 clases representativas.

Adicionalmente, se extrajo información técnica desde las columnas *Versión* y *Título* para completar variables como *Motor*, *Tracción*, *Caja* y *Cámara de retroceso*. En los casos con valores faltantes, como la cilindrada del motor o los caballos de fuerza, se imputaron los datos utilizando registros de otros autos con la misma versión, ya que comparten esas características técnicas.

D. Transformaciones adicionales

Las variables categóricas fueron tratadas de acuerdo a su cardinalidad:

- **Target encoding:** se aplicó a variables de alta cardinalidad como *Marca*, *Modelo* y *Versión*, asignando valores numéricos promedio del target por categoría.
- **One-hot encoding:** se utilizó en variables con pocos niveles como *Tracción*, *Tipo de combustible*, *Transmisión*, *Moneda* y *Tipo de vendedor*.

Se eliminaron los valores atípicos extremos en la variable *Kilómetros* (más allá del percentil 90), y se normalizaron las variables numéricas mediante escalado estándar para favorecer la estabilidad durante el entrenamiento de los modelos.

E. Experimentos descartados

Se exploraron distintas estrategias que finalmente no fueron incluidas en el modelo final por no aportar mejoras significativas o por bajo rendimiento:

- **VAEs sobre descripciones:** se generaron embeddings del campo *Descripción* mediante TF-IDF, seguidos de una reducción de dimensionalidad con autoencoders variacionales (VAEs). Si bien se lograron representaciones compactas, esto no mejoró la performance del modelo de regresión.
- **Clasificación de daños:** se intentó detectar si un auto presentaba daños a partir de su descripción. Para ello

se definieron etiquetas automáticas mediante expresiones regulares que buscaban palabras clave como 'roto', 'detalles', etc., y luego se utilizó un modelo de lenguaje para refinar esa clasificación. Sin embargo, el clasificador resultante no fue fiable y no aportó información útil a la predicción de precios.

- **Identificación de precios como señal:** se intentó generar una variable binaria que identificara publicaciones en las que el precio publicado correspondía al anticipo o señal, y no al valor total del vehículo. Se utilizaron expresiones regulares para detectar palabras como anticipo” o cuotas”. La incorporación de esta variable disminuyó la performance del modelo en aproximadamente 0,02 puntos de R^2 , por lo que fue descartada.

III. METODOLOGÍA

En este trabajo abordamos el problema de predicción del precio de vehículos como una tarea de regresión supervisada. Para ello, se entrenaron y compararon diversos modelos, desde un baseline lineal hasta modelos no lineales más complejos. Esta sección describe los fundamentos teóricos, las implementaciones utilizadas y la estrategia de validación adoptada.

A. Formulación del problema

Sea $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$ un conjunto de datos de entrenamiento, donde $x_i \in \mathbb{R}^d$ representa las características del i -ésimo vehículo (como marca, modelo, año, etc.) y $y_i \in \mathbb{R}$ su precio. El objetivo de la regresión es aprender una función $f: \mathbb{R}^d \rightarrow \mathbb{R}$ tal que las predicciones $\hat{y}_i = f(x_i)$ se aproximen a los verdaderos valores y_i .

Para estimar los parámetros del modelo se utiliza como función de pérdida el *error cuadrático medio* (RMSE), definido como:

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

Este criterio penaliza con mayor severidad los errores grandes, lo que resulta apropiado en contextos donde las desviaciones importantes en el precio tienen un mayor impacto práctico.

B. Modelos utilizados

Regresión lineal: La regresión lineal busca una relación lineal entre las variables de entrada y la salida. El modelo asume:

$$f(x) = x^\top \beta + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2)$$

donde $\beta \in \mathbb{R}^d$ son los coeficientes a estimar. Se trata del modelo más simple y se utilizó como baseline para evaluar el valor agregado de modelos no lineales.

Random Forest: Los *Random Forests* (Bosques Aleatorios) consisten en un ensamble de múltiples árboles de regresión entrenados sobre subconjuntos aleatorios del conjunto de entrenamiento y de las variables. La predicción se obtiene como el promedio de las predicciones individuales de los árboles:

$$\hat{y} = \frac{1}{T} \sum_{t=1}^T f_t(x)$$

donde $f_t(x)$ es la predicción del árbol t -ésimo. Esta técnica reduce la varianza del modelo y mejora la generalización.

XGBoost: XGBoost (*Extreme Gradient Boosting*) es un algoritmo basado en boosting de árboles de decisión. A diferencia de Random Forests, los árboles se entrenan secuencialmente, corrigiendo los errores del conjunto anterior. El modelo general se construye como:

$$f(x) = \sum_{t=1}^T f_t(x), \quad f_t \in \mathcal{F}$$

donde $\mathcal{F}$ es el espacio de árboles de regresión y los f_t se optimizan para minimizar una pérdida regularizada del tipo:

$$\mathcal{L} = \sum_{i=1}^N \ell(y_i, \hat{y}_i) + \sum_{t=1}^T \Omega(f_t)$$

con $\Omega(f_t)$ una penalización sobre la complejidad del árbol (profundidad, número de hojas, etc.). XGBoost es altamente eficiente, escalable y robusto frente a outliers y valores faltantes.

Perceptrón Multicapa (MLP): El *Multilayer Perceptron* es una red neuronal *feedforward* compuesta por capas ocultas con activaciones no lineales. Denotando cada capa como

$$h^{(l)}(x) = \sigma(W^{(l)}x + b^{(l)}),$$

donde σ es la función de activación (ReLU en nuestro caso), y $W^{(l)}$, $b^{(l)}$ son los pesos y sesgos de la capa l . Este modelo tiene la capacidad de aproximar funciones no lineales complejas, aunque requiere una cuidadosa regularización para evitar el sobreajuste.

C. Evaluación y selección de modelos

Se utilizó una estrategia de validación con *hold-out*: el conjunto de entrenamiento se dividió en un 80% para entrenamiento y un 20% para validación. Los modelos fueron entrenados minimizando la función de pérdida RMSE y comparados entre sí utilizando la métrica R^2 sobre el conjunto de validación:

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

Los modelos con mejor desempeño en validación fueron luego evaluados en el conjunto de testeo final para estimar su capacidad de generalización.

IV. RESULTADOS

En esta sección se presentan los resultados obtenidos durante el entrenamiento y evaluación de los distintos modelos. Se compararon métricas de desempeño antes y después de la optimización de hiperparámetros, destacando el comportamiento de cada modelo y analizando los factores que llevaron al mejor rendimiento.

A. Comparación de modelos

Para este baseline, se probaron inicialmente todos los modelos con un dataset que pasó por un preprocesamiento rápido. Este proceso eliminó las variables más complejas y aplicó transformaciones sencillas al resto, con el objetivo de obtener una evaluación inicial rápida del desempeño de cada modelo. Posteriormente, para la búsqueda de hiperparámetros, se utilizó un dataset más completo y refinado.

Se entrenaron cuatro modelos: regresión lineal, Random Forest, XGBoost y un perceptrón multicapa (MLP). La regresión lineal fue utilizada como baseline y obtuvo un desempeño considerablemente inferior al de los modelos no lineales. La métrica principal de comparación fue el coeficiente de determinación R^2 , calculado sobre el conjunto de validación. El primer experimento fue realizado sobre un dataset más simple y no optimizado.

TABLE II
DESEMPEÑO DE LOS MODELOS ANTES Y DESPUÉS DE LA OPTIMIZACIÓN

Modelo	R^2 Inicial	R^2 Optimizado
Regresión Lineal	0.7986	n/a
Random Forest	0.8756	0.9293
XGBoost	0.8871	0.9451
MLP	0.8034	0.3178

[completar] indica campos a completar con resultados reales.

Los resultados muestran que, si bien XGBoost ya presentaba un buen rendimiento desde el inicio, todos los modelos (excepto la regresión lineal) mejoraron significativamente tras la optimización de hiperparámetros. XGBoost alcanzó el mejor desempeño con un R^2 cercano a 0.93, seguido por Random Forest. En el caso del MLP, si bien su rendimiento inicial fue razonable, su desempeño posterior se vio afectado. Creemos que con mas tiempo y preprocesamiento la red neural deberia poder alcanzar el resto de modelos.

B. Técnicas de optimización de hiperparámetros

Se aplicaron tres enfoques distintos para la búsqueda de hiperparámetros:

- **Random Grid Search:** muestreo aleatorio dentro de un grid predefinido.
- **Bayesian Optimization:** búsqueda guiada por modelos probabilísticos.
- **Optuna:** optimización secuencial basada en árboles de Parzen estimators.

Cada técnica de optimización de hiperparámetros fue aplicada sobre los modelos Random Forest, XGBoost y MLP, evaluando múltiples combinaciones a lo largo de varias iteraciones.

Los hiperparámetros más relevantes para cada modelo fueron los siguientes:

- **XGBoost:** *Learning rate, max depth, n estimators, subsample, colsample_bytree, gamma, reg_alpha, reg_lambda.*
- **Random Forest:** *Max depth, n estimators, min samples split, min samples leaf, max features, bootstrap.*
- **MLP:** *Número de capas, número de neuronas, función de activación, regularización (alpha), learning rate, número de iteraciones, early stopping, batch size.*

C. Análisis cualitativo del desempeño

Para analizar el desempeño cualitativo del modelo, se examinaron los residuos, es decir, la diferencia entre los precios reales y los precios predichos. El gráfico de residuos (Figura 2) permite visualizar la distribución de estos errores y detectar posibles patrones o sesgos en las predicciones.

Además del análisis visual de los residuos, se investigaron los 10 datos con mayor error individual, pero no se encontró una correlación o patrón claro que explicara por qué el modelo fallaba significativamente en esos casos específicos. Esto sugiere que los errores grandes podrían ser casos aislados de valores atípicos, errores de carga en el dataset, o características muy particulares no capturadas por el modelo.

También se analizaron las marcas de vehículos que presentaban un mayor error promedio (MAE) y aquellas con más cantidad de datos y su RMSE. A continuación, se presentan las tablas con los resultados:

TABLE III
TOP 10 MARCAS CON MAYOR MAE

Marca	MAE
Porsche	3.064e+07
Haval	2.040e+07
DS AUTOMOBILES	1.371e+07
Mercedes-Benz	1.352e+07
D-S	1.284e+07
Land Rover	9.941e+06
Mitsubishi	9.828e+06
Lexus	9.295e+06
Jetur	8.829e+06
Isuzu	8.416e+06

Las marcas con mayor MAE (Mean Absolute Error) tienden a ser marcas de lujo o menos comunes, como Porsche, Haval y DS AUTOMOBILES. Esto podría deberse a la menor cantidad de datos disponibles para estas marcas, lo que dificulta al modelo aprender patrones de precios robustos, o a la mayor variabilidad de precios intrínseca a estos segmentos del mercado. Aunque no se encontró una correlación directa en los 10 datos con mayor error, se mantiene la expectativa de que las principales fuentes de desviación estén asociadas a publicaciones con precios extremos, errores de carga o versiones con pocos datos representativos. A pesar de los errores puntuales, el desempeño general de XGBoost sigue siendo robusto.




Fig. 2. Gráfico de residuos: diferencias entre precios reales y predichos.

D. Discusión del mejor modelo

XGBoost resultó ser el modelo con mejor desempeño, debido a su capacidad para capturar relaciones no lineales entre las variables, su manejo interno de valores faltantes y su robustez frente a outliers. Además, su estrategia de boosting secuencial permite corregir errores iterativamente, lo que se tradujo en una mejora considerable respecto al baseline lineal y los otros modelos no lineales.

La diferencia de rendimiento entre XGBoost y los demás modelos se redujo después de la optimización, especialmente en el caso del Random Forest, que alcanzó un rendimiento competitivo. Sin embargo, la estabilidad y capacidad de generalización de XGBoost justificaron su elección como modelo final.

Una vez seleccionado, el modelo fue evaluado sobre el conjunto de *hold-out* separado al comienzo del pipeline experimental. Los resultados obtenidos fueron:

TABLE IV
RESULTADOS DEL MODELO SOBRE LOS CONJUNTOS TRAIN, VALIDATION Y TEST

Conjunto	R^2	RMSE	MAE
Entrenamiento (Train)	0.9801	3 999 884.40	2 103 002.71
Validación (Validation)	0.9517	5 915 242.41	2 985 798.44
Test (Hold-out)	0.9440	6 978 498.43	3 138 756.06

Estos resultados muestran un buen equilibrio entre ajuste y generalización, confirmando que el modelo no sobreajustó al conjunto de entrenamiento y mantiene un rendimiento consistente en los datos no vistos.

V. CONCLUSIÓN

El desarrollo de un modelo predictivo para estimar el precio de SUVs publicados en MercadoLibre demostró ser una tarea factible con resultados alentadores. A través de un proceso riguroso de limpieza y transformación de datos, combinado con una evaluación comparativa de diversos algoritmos de

regresión, se logró identificar un modelo (XGBoost) con alto poder predictivo.

Los resultados obtenidos muestran que el modelo es capaz de generalizar adecuadamente a nuevas observaciones, lo que lo convierte en una herramienta potencialmente útil tanto para compradores como para vendedores en el mercado automotor argentino. La precisión alcanzada, con un R^2 de 0.944 y un RMSE cercano a los 6.000 dólares, evidencia la capacidad del enfoque propuesto para capturar relaciones complejas entre las variables del dataset.

Como trabajo futuro, se sugiere ampliar el análisis a otros segmentos del mercado automotor, incorporar datos históricos para modelar tendencias de precios en el tiempo, y explorar el uso de modelos más avanzados como LightGBM o redes neuronales profundas.